Diccionario de Datos
DS3021 Análisis Computacional de Datos

Variable	***Descripción***	***Tipo***	***Tamaño máximo***	***Valores***	***Unidad***
product	Nombre de publicación tal cuál aparece en Falabella, está normalizado (mayúsculas, sin espacios dobles, comillas tipográficas ni punto final).	Texto	131 caracteres	931 valores distintos (texto libre)	-
brand	Marca declarada en la publicación, está en mayúsculas. GENERICO es la etiqueta de la tienda cuando el vendedor no declara marca.	Categórico	12 caracteres	40 valores distintos. Más frecuentes: LENOVO (154), SAMSUNG (134), APPLE (122), ASUS (109)	-
category	Sección de Falabella desde la que se obtuvo la publicación (televisores, celulares o laptops).	Categórico	7 caracteres	laptops, phones, tvs	-
seller	Vendedor de la publicación. Ejem: Falabella, sus filiales (Tottus, Sodimac) o un vendedor externo del marketplace.	Categórico	36 caracteres	186 valores distintos. Más frecuentes: FALABELLA (113), JA INNOVATION (37), NORTICO PE (36), TOTTUS (32)	-
list_price	Precio de lista (el precio tachado). Cuando la publicación no mostraba precio tachado se imputó con internet_price (ver list_price_imputed).	Numérico	7 (5 enteros + 2 decimales)	159.00 a 79,999.00	Soles (S/)
internet_price	Precio de venta en línea, el precio internet o, en caso de no existir, el precio de evento. No incluye el precio exclusivo con tarjeta CMR.	Numérico	7 (5 enteros + 2 decimales)	79.90 a 27,345.56	Soles (S/)
cmr_price	Precio exclusivo con tarjeta CMR Falabella. Queda vacío cuando la publicación no ofrece precio CMR.	Numérico	7 (5 enteros + 2 decimales)	299.00 a 13,499.00. Vacío = sin precio CMR	Soles (S/)
list_price_imputed	Marca las filas cuyo list_price estaba vacío y se completó con internet_price (osea, producto sin descuento).	Categórico (binario)	1	0 = valor original, 1 = imputado	-
is_price_outlier	Marca precios atípicos, internet_price fuera de Q1 - 1.5 IQR o de Q3 + 1.5 IQR, calculados dentro de su categoría. No se eliminan, solo se marcan.	Categórico (binario)	1	0 = no atípico, 1 = atípico	-

I. Limitaciones por variable

product: No hay SKU ni URL, el nombre no identifica un modelo único y puede incluir color, almacenamiento o combos (por ejemplo "+ MOUSE"). Varias publicaciones comparten nombre.

brand: 11 filas son GENERICO y se conservan como categoría explícita (no se imputó marca).

category: Es la sección de scraping, no una clasificación del producto. Los accesorios colocados en la sección se retiraron con reglas basadas en el nombre.

seller: Texto libre normalizado, no se verificó si razones sociales distintas pertenecen al mismo dueño. El tipo de vendedor (Falabella o tercero) se construye en feature engineering.

list_price: El supuesto "sin precio tachado = sin descuento" proviene del código del spider, no de una verificación manual en la tienda. Hay errores de digitación del vendedor sin corregir: una laptop tiene precio de lista de S/ 79,999 contra un precio internet de S/ 5,699.

internet_price: Una sola captura en el tiempo: no permite medir la evolución de precios.

cmr_price: Vacío en 857 filas (82.5%) porque la publicación no tiene precio CMR, no se imputa. Para calcular el ahorro con tarjeta se usan solo las filas con valor.

list_price_imputed: 36 filas (3.5%) están imputadas, sirve para excluirlas o revertir la imputación.

is_price_outlier: 53 filas marcadas (5.1%). Todas son de precio alto (gama alta de cada categoría): la distribución de precios tiene cola a la derecha. Son productos reales, no errores de captura.