

UNIVERSIDAD DE INGENIERÍA Y TECNOLOGÍA



FACULTAD DE COMPUTACIÓN

CARRERA DE DATA SCIENCE

PRIMER AVANCE DEL PROYECTO FINAL:

*Análisis de precios, descuentos y competitividad comercial en productos tecnológicos de
Falabella Perú*

INTEGRANTES:

Axel Roberth Portal Ruiz

Alondra Solange Obregon Carhuavilca

Danna Nickol Gala Vásquez

Gerald Marcelo Fernando Borjas Bernaola

ANÁLISIS COMPUTACIONAL DE DATOS

LIMA - PERÚ

2026

Índice General

1. Identificación	2
2. Contexto	2
3. Objetivos	3
4. Dataset Preliminar	3
5. Alcance	4
6. Fuentes de Datos	6
7. Estrategia	6
8. Viabilidad	8

§ 1. Identificación

Para el presente proyecto, se desarrolló la siguiente distribución de responsabilidades:

Integrante	Responsabilidad
Alondra Obregón	Objetivos, Dataset Preliminar, Viabilidad, Apoyo en Web Scra- ping
Axel Portal	Identificación, Fuente de Datos, Estrategia, Apoyo en Web Scra- ping
Danna Gala	Contexto, Alcance, Diccionario de Datos, Notebook de validación de dataset
Gerald	Web Scraping de la página seleccionada

Tabla 1: Distribución de responsabilidades

§ 2. Contexto

El crecimiento del comercio electrónico ha incrementado la cantidad de productos y vendedores disponibles en plataformas de marketplace, generando así una mayor variedad de alternativas para los consumidores. En plataformas como Falabella Perú, un mismo tipo de producto puede encontrarse asociado a diferentes marcas, precios, descuentos y vendedores, esto incluyendo tanto la venta directa de la plataforma como ofertas realizadas por terceros.

Esta variedad dificulta poder realizar comparaciones directas entre productos y vendedores, especialmente en categorías tecnológicas con alto valor como lo podrían ser laptops, celulares y televisores. Un producto puede presentar al mismo tiempo un precio normal y un precio de oferta, esto mientras que otros productos de características similares pueden ser comercializados por distintos vendedores a precios diferentes. Por ello, observar únicamente el precio de un producto nos permitiría identificar con claridad cómo se distribuyen los precios, qué magnitud tienen los descuentos o cómo varían estas características entre marcas y tipos de vendedores.

Bajo este contexto, nuestro proyecto propone utilizar técnicas de web scraping y análisis exploratorio de datos para poder construir un dataset a partir de productos publicados en la plataforma de *Falabella Perú*. Este análisis nos permitirá caracterizar los precios normales y de oferta, calcular los porcentajes de descuento y comparar estas variables según categoría, marca y vendedor. De esta manera, se busca obtener una descripción cuantitativa de la oferta tecnológica disponible en la plataforma y de las diferencias observables entre sus distintos tipos de vendedores.

§ 3. Objetivos

Objetivo General

Analizar los precios, descuentos y niveles de competencia entre las marcas de laptops, celulares y televisores en Falabella Perú, comparando las ventas directas con las de los vendedores del marketplace.

Objetivos Específicos

- *Evaluar la magnitud y distribución de los descuentos:*

Cuantificar la brecha porcentual entre el precio normal y el precio de oferta en las tres categorías tecnológicas, determinando qué líneas presentan rebajas más agresivas y cuáles mantienen precios de venta rígidos.

- *Contrastar la competitividad tarifaria entre tipos de vendedores:*

Comparar las distribuciones de precios ofertados por Falabella y sus filiales directas frente a los vendedores externos (sellers), identificando si los terceros constituyen una opción más económica o si replican las tarifas oficiales en los mismos modelos.

- *Examinar el posicionamiento y la dispersión de costos por marca:*

Determinar las diferencias de precios promedio y rangos de dispersión entre las principales marcas de cada categoría (ej. Apple, Samsung, Lenovo, LG), clasificando su presencia en segmentos de gama de entrada, media y alta dentro de la plataforma.

§ 4. Dataset Preliminar

El resultado de la extracción es un archivo `.csv` con **1680 filas y 7 columnas**, repartidas en siete secciones relacionadas con el servicio de retail (producto, marca, categoría, vendedor, precio regular, precio especial y hay descuento con cmr). Cada fila representa un producto y cada columna es un atributo respecto a dicho producto:

Atributo	Descripción
product	Nombre completo del producto tal como aparece en el sitio.
brand	Marca del producto.
category	La categoría del producto es teléfono, televisor o laptop.
seller	Nombre del vendedor del producto.
regular_price	Precio regular sin descuento del producto, en soles.
special_price	Precio con descuento, en soles.
has_cmr_discount	Si el producto cuenta con algún descuento extra por pagar con tarjeta cmr.

Tabla 2: Atributos del dataset preliminar

product	brand	category	seller	regular_price	special_price	has_cmr_discount
Celular Galaxy S26 512GB	SAMSUNG	phones	FALABELLA	5399.0	4199.0	0
MacBook Neo 512GB - Índigo	APPLE	laptops	TECHNOLOGY SUPPLIER PE	4539.0	3699.0	1
Televisor 32 QLED Full HD Smart TV 32S5K	TCL	tns	CITY TEC PERU	899.0	479.0	0

Tabla 3: Muestra de 3 registros del dataset preliminar

Este es el dataset preliminar, tal como sale luego de realizar el scraping, por lo que, puede presentar errores de múltiples tipos (tipo de datos, ortográficos, etc) en ciertos registros que se corregirán luego al pasar por un proceso de limpieza para lograr su posterior análisis en la siguiente entrega. Del mismo modo, mediante el uso de pandas, hemos buscado garantizar que la cantidad de nulos (NA) por columna no superé el 10% y estos fueron los resultados obtenidos:

	Nulos	% de nulos
regular_price	121	7.2
product	0	0.0
brand	0	0.0
category	0	0.0
seller	0	0.0
special_price	0	0.0
has_cmr_discount	0	0.0

Tabla 4: Resumen de porcentaje de valores nulos (NA) por columna del dataset

Tras observar los resultados, encontramos que la única columna con datos nulos corresponde a regular_price con 7.2% de datos NA, por lo que no supera el límite de 10% establecido. Entonces, el dataset preliminar con el que contamos, cumple en su totalidad con los requisitos establecidos.

§ 5. Alcance

El proyecto se centrará en la recopilación y análisis de información pública disponible en Falabella Perú para productos pertenecientes a las categorías de laptops, celulares y televisores. La información será obtenida mediante técnicas de web scraping y posteriormente será organizada en un dataset estructurado para su análisis.

Dentro del alcance

- La recopilación de información de productos publicados en las tres categorías seleccionadas.
- La identificación de atributos como nombre del producto, marca, categoría, vendedor, precio normal, precio de oferta y calificación, cuando estos se encuentren disponibles.
- El cálculo del porcentaje de descuento a partir de los precios normal y de oferta.
- El análisis exploratorio de la distribución de precios y descuentos.
- La comparación de precios y descuentos entre las categorías estudiadas.
- El análisis de las diferencias de precios según marca.
- La comparación entre productos comercializados directamente por Falabella y productos ofrecidos por vendedores externos del marketplace, cuando dicha información pueda ser identificada en los datos recopilados.
- La identificación y análisis de valores atípicos, datos faltantes y posibles duplicados presentes en el dataset.
- La utilización de tablas y visualizaciones para facilitar la interpretación de los resultados.

Fuera del alcance

- El seguimiento de la evolución de los precios a lo largo del tiempo, debido a que el análisis se realizará sobre los datos recopilados durante el periodo definido para el proyecto.
- La determinación de las ventas reales, ingresos o rentabilidad de Falabella o de los vendedores externos, debido a que estas variables no forman parte de la información recopilada.
- La evaluación de la calidad, desempeño o autenticidad de los productos.
- El análisis del comportamiento individual de los consumidores o de sus decisiones de compra.
- La evaluación de costos logísticos, tiempos de entrega, garantías u otros factores que no formen parte del dataset obtenido.
- La realización de inferencias causales sobre las razones por las cuales un vendedor establece determinado precio o descuento.
- La comparación con otras plataformas de comercio electrónico que no formen parte de la fuente de datos definida para el proyecto.

§ 6. Fuentes de Datos

La información para el proyecto se extrajo de la web oficial de Falabella Perú:

<https://www.falabella.com.pe/falabella-pe>

Específicamente, se obtuvo la información de las categorías:

- Laptops: <https://www.falabella.com.pe/falabella-pe/category/cat40712/Laptops>
- Televisores: <https://www.falabella.com.pe/falabella-pe/category/cat6370551/Televisores-Smart-TV>
- Celulares: <https://www.falabella.com.pe/falabella-pe/category/cat760706/Celulares-y-Telefonos>

La selección de *Falabella Perú* como fuente principal se justifica por ser una plataforma de comercio electrónico líder en el mercado peruano, lo que garantiza un alto nivel de representación e interés local para un análisis de datos. Al ser un sitio de acceso libre y público, permite la extracción ética y continua de datos sin barreras de autenticación. Asimismo, la estructura HTML de la plataforma presenta plantillas consistentes y paginación organizada, aspectos esenciales para asegurar la factibilidad técnica y la reproducibilidad del web scraping. Finalmente, la plataforma ofrece una amplia variedad y densidad de atributos organizados por producto (como precio normal, precio de oferta, tarjetas de descuento, vendedor o seller, marca y calificación), lo cual brinda el detalle necesario para construir un dataset sólido, diverso y superior a los registros requeridos para el análisis y cumplimiento de los objetivos.

§ 7. Estrategia

Para la obtención de datos se utilizó Python y Scrapy, debido a su eficiencia, velocidad y capacidad para extraer de forma estructurada los datos. El proceso del web scraping fue el siguiente:

Navegación automatizada Se definieron las URLs estáticas de tres categorías principales de Falabella Perú (Celulares, Laptops y Televisores). Para lograr el volumen de datos requerido, se aplicó un método de paginación inyectando el parámetro `?page={}` en un bucle que *iteró hasta 20 páginas por categoría*.

Parseo y Extracción Al descargar el código fuente, la extracción se realizó mediante Selectores CSS, identificando los contenedores principales de las tarjetas de productos (`div.grid-pod`). Dentro de estas, se aislaron atributos específicos para cruzar los distintos niveles de precios (`data-normal-price`, `data-internet-price`, `data-cmr-price`).


Transformación y limpieza Para asegurar la calidad de los datos, el script incluye funciones de limpieza durante el mismo proceso de extracción. Los textos extraídos (como el prefijo `Por` en los vendedores) son depurados, los precios son convertidos

directamente a valores numéricos (float), y los descuentos especiales (CMR) se transforman en variables categóricas binarias (1/0).

Almacenamiento Continuo Los datos estructurados fluyen hacia un archivo .csv mediante un proceso de escritura incremental, garantizando la integridad de la información en tiempo real.

Por otro lado, dado que las plataformas e-commerce suelen implementar medidas contra la extracción automatizada, se desarrollaron medidas de contingencia.

Inicialmente, se revisó el archivos robots.txt de Falabella Perú:



```
# En falabella.com nuestro propósito es simplificar y disfrutar más la vida, es por ello que los robots deben compartir nuestros valores:
# Somos un solo equipo, y por eso todos los robots son bienvenidos:
User-agent: *
Disallow:

# Nos movemos ágilmente, facilitamos todas las URLs que son interesantes de rastrear por los robots:
Sitemap: https://www.falabella.com.pe/estatic/site/sitemaps/collections/collections_pe_FA_COM-index.xml
Sitemap: https://www.falabella.com.pe/estatic/site/sitemaps/landings/landings_pe_FA_COM-index.xml
Sitemap: https://www.falabella.com.pe/estatic/site/sitemaps/brands/brands_pe_FA_COM-index.xml
Sitemap: https://www.falabella.com.pe/estatic/site/sitemaps/pdp/pdp_pe_FA_COM-index.xml
Sitemap: https://www.falabella.com.pe/estatic/site/sitemaps/calliers/sellers_pe_FA_COM-index.xml
Sitemap: https://www.falabella.com.pe/estatic/site/sitemaps/categories/categorias_pe_FA_COM-index.xml
Sitemap: https://www.falabella.com.pe/estatic/site/sitemaps/categoriesFacetType/categoriesFacetType_pe_FA_COM-index.xml
Sitemap: https://www.falabella.com.pe/estatic/site/sitemaps/categoriesFacetBrand/categoriesFacetBrand_pe_FA_COM-index.xml
Sitemap: https://www.falabella.com.pe/estatic/site/sitemaps/categoriesFacetBackMaterial/categoriesFacetBackMaterial_pe_FA_COM-index.xml
Sitemap: https://www.falabella.com.pe/estatic/site/sitemaps/categoriesFacetBackrest/categoriesFacetBackrest_pe_FA_COM-index.xml
Sitemap: https://www.falabella.com.pe/estatic/site/sitemaps/categoriesFacetRoof/categoriesFacetRoof_pe_FA_COM-index.xml
Sitemap: https://www.falabella.com.pe/estatic/site/sitemaps/categoriesFacetNumberofBusses/categoriesFacetNumberofBusses_pe_FA_COM-index.xml
Sitemap: https://www.falabella.com.pe/estatic/site/sitemaps/categoriesFacetNumberofDoors/categoriesFacetNumberofDoors_pe_FA_COM-index.xml
Sitemap: https://www.falabella.com.pe/estatic/site/sitemaps/categoriesFacetNumberofPositions/categoriesFacetNumberofPositions_pe_FA_COM-index.xml
Sitemap: https://www.falabella.com.pe/estatic/site/sitemaps/categoriesFacetNumberofThreads/categoriesFacetNumberofThreads_pe_FA_COM-index.xml
Sitemap: https://www.falabella.com.pe/estatic/site/sitemaps/categoriesFacetProcessor/categoriesFacetProcessor_pe_FA_COM-index.xml
Sitemap: https://www.falabella.com.pe/estatic/site/sitemaps/categoriesFacetMemory/categoriesFacetMemory_pe_FA_COM-index.xml
Sitemap: https://www.falabella.com.pe/estatic/site/sitemaps/categoriesFacetResolution/categoriesFacetResolution_pe_FA_COM-index.xml
Sitemap: https://www.falabella.com.pe/estatic/site/sitemaps/categoriesFacetStructuralMaterial/categoriesFacetStructuralMaterial_pe_FA_COM-index.xml
Sitemap: https://www.falabella.com.pe/estatic/site/sitemaps/categoriesFacetShabCapacity/categoriesFacetShabCapacity_pe_FA_COM-index.xml
Sitemap: https://www.falabella.com.pe/estatic/site/sitemaps/categoriesFacetScreenSize/categoriesFacetScreenSize_pe_FA_COM-index.xml
Sitemap: https://www.falabella.com.pe/estatic/site/sitemaps/shop/shop_pe_FA_COM-index.xml

# Nos apasionamos por el cliente
# Cuidamos el futuro, por ello creemos no es importante perder tiempo en estos lugares:
User-agent: *
Disallow: /cgi-bin/
Disallow: /falabella-pe/basket*
Disallow: /falabella-pe/myaccount*
Disallow: /falabella-pe/checkout*
Disallow: /falabella-pe/orders*
```

Figura 1: Archivo robots.txt de Falabella Perú

Se observa que Falabella permite y facilita la obtención de toda la información pública de productos, categorías y marcas. No obstante, está prohibido extraer datos de:

- El carrito de compras (/falabella-pe/basket*)
- Páginas de cuentas de usuario (/falabella-pe/myaccount*)
- El proceso de pago o caja (/falabella-pe/checkout*)
- El historial de pedidos (/falabella-pe/orders*)
- Directorios del servidor (/cgi-bin/)

Por lo tanto, la obtención de estos datos queda totalmente fuera del alcance del proyecto.

Adicionalmente, se implementaron los siguientes mecanismos de contingencia:

Evasión de Bloqueos por Saturación (AutoThrottle) En lugar de hacer múltiples peticiones por segundo, se activó la extensión AutoThrottle de Scrapy. Esta

herramienta analiza la latencia del servidor de Falabella y ajusta dinámicamente los tiempos de espera entre peticiones (entre 1 y 5 segundos), simulando un comportamiento humano e impidiendo que nuestra IP sature el sitio web o active los firewalls por límite de peticiones.

Headers Se configuró una cabecera HTTP `USER_AGENT` realista que emula un sistema operativo y navegador de un usuario común, mitigando el rechazo por parte de los filtros básicos de seguridad del servidor.

Manejo de Caídas de Red (Try-Except y Errbacks) Ante la posibilidad de rechazos de conexión, cuelgues del servidor o errores DNS, se implementó una función `errback_handler` en las peticiones. Esta función utiliza bloques `try-except` para atrapar las excepciones, registrar el fallo en un archivo log sin detener la ejecución del script, y trabajar en conjunto con el `RetryMiddleware` de Scrapy para reintentar la conexión de manera automática.

Prevención de Pérdida de Datos Gracias al almacenamiento en flujo de Scrapy y la pipeline orientada a bases de datos (Supabase), un eventual baneo definitivo de IP a mitad del proceso no provocaría la pérdida del dataset; todos los registros raspados hasta el segundo previo a la desconexión quedarían guardados y utilizables.

§ 8. Viabilidad

El proyecto es viable en cuanto a recursos y herramientas ya que hacemos uso herramientas gratuitas y de código abierto: Python, Pandas, Scrapy, Visual Studio Code y Supabase siendo usado con su plan gratuito. Por lo tanto, no tenemos la necesidad de pagar por algún servicio extra para poder desarrollar el proyecto en su totalidad.

En lo que respecta a tiempo, haber dividido las múltiples tareas relacionadas al proyecto, nos permitió avanzar en simultáneo y así, ir a la par con los tiempos. Una estrategia que fue usada para evitar el bloqueo de la IP del integrante encargado del Scraping fue utilizar proxys gratuitos, lo que llevó a que la tarea fuera un poco más tardada, pero aseguraba que pudiéramos completar el Scraping en una sola corrida del código, obteniendo al final una totalidad de 1680 registros, lo cual entra de la cantidad mínima de registros solicitados. Del mismo modo, no buscamos ser ambiciosos con la cantidad de datos a extraer ya que ello podría extender el tiempo que pueda tardar en realizarse el scraping por completo por lo que, escogimos extraer datos en una sola tanda para poder trabajar dentro de los plazos establecidos.

Un punto extra que nos gustaría mencionar es la parte de viabilidad legal. Nuestro proyecto no extrae información sensible o prohibida por Falabella, sin embargo, igual hemos establecido `robots.txt = TRUE`, lo que prohíbe a nuestra spider el extraer algún dato prohibido por *Falabella*, aunque, no queramos extraer dicha información sensible, fue una medida extra para asegurar la integridad de los datos a extraer.